

# SPORT ONE

## Projet SportOne

SAE S3 Intégration de données  
dans un Data Warehouse

# RAPPORT

**Groupe : n°8**

Présentés par

**Toni Robert**

**Ely Mouthon**

**Remi Misery**

**Nathan Simian**



---

## Sommaire

|                                                                   |          |
|-------------------------------------------------------------------|----------|
| 1. Introduction et Contexte .....                                 | p. 3     |
| 2. Architecture et Modélisation (Oracle) .....                    | p. 3 - 4 |
| 3. Préparation et Intégration des Données (Python & Talend) ..... | p. 4 - 5 |
| 4. Visualisation des Données (Power BI) .....                     | p. 5     |
| 5. Organisation et Bilan.....                                     | p. 6     |

---

## 1. Introduction et Contexte

La société **SportOne** est un distributeur international d'articles de sport vendant ses produits via des magasins physiques et un site e-commerce. L'entreprise dispose d'un historique de données de 5 ans (mars 2017 à mars 2022), mais ces informations sont actuellement dispersées dans des fichiers de formats variés (CSV, Excel, Access) et présentent des problèmes de qualité.

L'objectif de ce projet est de construire une chaîne décisionnelle complète pour valoriser ces données. Notre mission s'est déroulée en deux phases techniques :

1. **Back-end** : La construction d'un entrepôt de données (Data Warehouse) centralisé et propre.
2. **Front-end** : La création de tableaux de bord interactifs pour piloter la performance commerciale.

Ce rapport présente les choix techniques effectués pour transformer ces données brutes en outils d'aide à la décision.

---


## 2. Architecture et Modélisation (Oracle)

Pour répondre aux besoins d'analyse, nous avons mis en place une base de données sous **Oracle SQL Developer**. Nous avons choisi une modélisation en **Schéma en Étoile**, structure standard en Business Intelligence qui sépare clairement les faits (chiffres) des axes d'analyse (contexte).

### 2.1. Structure de l'entrepôt

Notre schéma se compose de :

- **Une Table de Faits (Order\_Fact)** : C'est le cœur du système. Elle contient toutes les lignes de ventes avec les métriques clés : quantités vendues, chiffre d'affaires, remises et coûts.
- **Cinq Dimensions (Tables de référence)** : Elles permettent d'analyser les ventes sous différents angles :
  - **Qui ?** Customer\_Dim (Clients) et Organization\_Dim (Employés).
  - **Quoi ?** Product\_Dim (Produits).
  - **Où ?** Geography\_Dim (Lieux de vente et de livraison).
  - **Quand ?** Time\_Dim (Calendrier détaillé).



### 3. Préparation et Intégration des Données (ETL)

La phase la plus importante du projet a été l'ETL (Extraction, Transformation, Chargement). Avant d'injecter les données dans la base, nous avons dû les nettoyer et les uniformiser.

#### 3.1. Pré-traitement et Automatisation avec Python

Avant d'utiliser Talend, nous avons exploité le langage Python pour résoudre deux problèmes bloquants :

##### 1. Standardisation des fichiers sources :

Les fichiers fournis avaient des noms hétérogènes comportant des espaces, des accents et des mélanges de majuscules, ce qui risquait de provoquer des erreurs techniques. Nous avons créé un script pour renommer automatiquement tous les fichiers en format standard (minuscules, sans accents, sans espaces). Cela a rendu les données "propres" avant même leur lecture.

##### 2. Génération de la dimension Temps :

Les données sources ne contenaient pas de calendrier référentiel. Comme demandé, nous avons programmé un script Python pour générer la table

Time\_Dim couvrant toute la période (2017-2022), incluant les trimestres, mois et jours de la semaine.

### 3.2. Intégration via Talend Open Studio

Nous avons développé des Jobs Talend pour alimenter chaque table de notre schéma en étoile.

- **Nettoyage des données** : Nous avons traité les valeurs nulles et harmonisé les formats (ex: codes pays).
  - **Enrichissement** : Pour la dimension Client, nous avons calculé l'âge exact de chaque personne à partir de sa date de naissance, ainsi que les catégories d'âges via des formules Java intégrées au composant tMap.
  - **Jointures** : La table de faits a été remplie en croisant les fichiers de ventes avec nos dimensions (Lookups) afin de récupérer les identifiants techniques (IDs) nécessaires au schéma en étoile.
- 

### 4. Visualisation des Données (Power BI)

Une fois l'entrepôt Oracle alimenté, nous l'avons connecté à **Microsoft Power BI** pour la phase de restitution. Nous avons réalisé un ensemble de tableaux de bord interactifs (plus de 15 visuels).

#### Axes d'analyse développés

Nous avons structuré nos rapports pour répondre aux besoins stratégiques :

- **Vue Globale** : Suivi du Chiffre d'Affaires (CA) total, du panier moyen et de l'évolution annuelle.
- **Analyse Géographique** : Cartes interactives montrant la rentabilité par pays et par région.
- **Analyse Produits** : Classement des produits "Top Flop" (les plus et moins vendus) et rentabilité par catégorie.
- **Analyse Clients** : Segmentation des acheteurs par tranche d'âge (Jeune, Adulte, Senior) et par genre, permettant de cibler les profils les plus actifs.

Ces tableaux de bord permettent désormais à SportOne de filtrer les données dynamiquement pour prendre des décisions rapides.

---

## 5. Organisation et Bilan

### 5.1. Gestion de projet

Pour respecter la date limite du 11 janvier, nous avons réparti les tâches selon les compétences de chacun :

| Membre        | Tâches Principales                               |
|---------------|--------------------------------------------------|
| Ely Mouthon   | Conception SQL et création du rapport            |
| Remi Misery   | Développement Talend et renommage Python         |
| Toni Robert   | Développement Talend                             |
| Nathan Simian | Création des Dashboards Power BI et Mise en page |

### 5.2. Bilan

Ce projet nous a confrontés à la réalité du terrain : la complexité de traiter des données hétérogènes et dispersées.

Il nous a permis de valider trois compétences majeures :

- **La gestion du flux de données** : Nettoyer et unifier des sources variées pour garantir la qualité de l'information.
- **L'adaptabilité technique** : Combiner la puissance du code (Python) et l'efficacité des outils ETL (Talend) pour résoudre les blocages techniques.
- **La vision architecturale** : Concevoir un système complet, capable de transformer des données brutes en outils de pilotage stratégique.

En conclusion, l'entrepôt de données est désormais fonctionnel et répond concrètement aux besoins d'analyse de performance de SportOne.